

AGENTE CONVERSACIONAL PARA INTERAÇÃO APRIMORADA EM SISTEMAS

Artigo em produção - Checklist de produção

- ☐ Edição do artigo
 - ☐ Aplicar ABNT
 - ☐ Aplicar formatação da SATC
- ☐ Escrita
 - ☐ Resumo
 - ☒ Esqueleto
 - ☐ Revisão após finalizar o artigo
 - ☒ Introdução (preciso de umas referências)
 - ☐ Material e métodos
 - ☒ Abordagem geral
 - ☐ Procedimento experimental de cada alternativa
 - ☐ Resultados e discussão
 - ☐ Considerações finais
 - ☐ Referências
 - ☐ Formatar ABNT

Lucas de Castro Zanoni¹

Thyerri Fernandes Mezzari²

Resumo: Este trabalho apresenta o desenvolvimento de um agente conversacional baseado em inteligência artificial para aprimorar a interação entre usuários e sistemas. Utilizando técnicas avançadas de processamento de linguagem natural, o agente proposto visa simplificar a comunicação em interfaces complexas, proporcionando uma experiência digital unificada e adaptável às necessidades dos usuários. A metodologia inclui o desenvolvimento, implementação e avaliação do agente em ambientes reais de uso. Os resultados demonstram que a solução proposta contribui significativamente para a melhoria da acessibilidade e usabilidade dos sistemas, reduzindo barreiras de interação e promovendo uma comunicação mais fluida e intuitiva.

Palavras-chaves: agente conversacional, interação, sistema, inteligência artificial.

¹Graduando em Engenharia de software no semestre letivo de 2024-2. E-mail: castro.lucas290@gmail.com

²Professor do Centro Universitário UniSATC E-mail: thyerri.mezzari@satc.edu.br

1 INTRODUÇÃO

A evolução das interfaces de usuário tem gerado uma diversidade de padrões de design e usabilidade, resultando frequentemente em barreiras para a plena acessibilidade e interação dos usuários com os sistemas digitais. Com o aumento da complexidade do frontend e a multiplicidade de paradigmas de interação, muitos usuários enfrentam dificuldades significativas para utilizar efetivamente as funcionalidades oferecidas pelos sistemas computacionais modernos (Rapp et al. 2018) (Kocaballi et al. 2019).

Nesse cenário, os agentes conversacionais baseados em inteligência artificial emergem como uma alternativa promissora para simplificar a comunicação entre humanos e máquinas, oferecendo uma camada intermediária de interação que pode traduzir comandos em linguagem natural para ações específicas no sistema.

Estudos recentes têm demonstrado que agentes conversacionais podem aprimorar significativamente a experiência do usuário ao simplificar interações com sistemas complexos (Fast et al. 2017). Além disso, a implementação de interfaces baseadas em linguagem natural tem mostrado potencial para melhorar a usabilidade em contextos domésticos e inteligentes, reduzindo o tempo e o esforço necessários para completar tarefas complexas (Guo et al. 2024). Ademais, tais interfaces oferecem vantagens consideráveis em termos de acessibilidade, permitindo uma comunicação mais inclusiva e adaptável a usuários com diferentes necessidades especiais (Lister et al. 2020) (Deng 2023).

A problemática central desta pesquisa reside na questão: de que forma um agente conversacional baseado em IA pode potencializar a interação entre usuários e sistemas, promovendo uma comunicação fluida mesmo em ambientes com interfaces complexas? Essa pergunta reflete a necessidade crescente de soluções que democratizem o acesso à tecnologia, reduzindo a curva de aprendizado necessária para a utilização de sistemas especializados e tornando-os mais acessíveis para diferentes perfis de usuários.

Adicionalmente, trabalhos recentes indicam que avanços na arquitetura de modelos de IA, como o uso de transformers sem camadas de normalização, podem influenciar positivamente o desempenho e a eficiência desses agentes (Zhu et al. 2025).

A relevância deste estudo evidencia-se pelo potencial transformador que os agentes conversacionais representam para a área de interação humano-computador. Ao implementar um sistema intermediário capaz de interpretar linguagem natural e traduzi-la em ações específicas dentro de um sistema, cria-se uma ponte que permite aos usuários interagir de forma mais intuitiva e natural com as tecnologias digitais. Esta abordagem tem o potencial de mitigar as barreiras impostas por interfaces complexas, contribuindo para uma maior inclusão digital e para a melhoria da experiência do usuário em diversos contextos de aplicação.

2 PROCEDIMENTO EXPERIMENTAL

Este trabalho adota uma abordagem metodológica estruturada em múltiplas etapas para investigar e avaliar diferentes métodos de integração entre agentes conversacionais baseados em LLMs (Large Language Models) e sistemas computacionais. A pesquisa se desenvolve através de uma análise comparativa de quatro abordagens distintas de integração, cada uma com suas características, vantagens e limitações específicas.

O processo investigativo inicia-se com uma revisão sistemática da literatura sobre integrações entre LLMs e sistemas, estabelecendo uma base teórica sólida para a análise subsequente. Em seguida, são exploradas quatro abordagens principais de integração: (1) conexão direta com banco de dados, permitindo consultas e manipulações diretas; (2) integração via plugins ORM, facilitando o acesso através de camadas de abstração existentes; (3) integração via API/Swagger, utilizando interfaces padronizadas de comunicação; e (4) integração via Model Context Protocol (MCP), explorando um paradigma emergente de comunicação entre LLMs e sistemas.

Para cada abordagem, será desenvolvida uma prova de conceito que demonstre sua viabilidade técnica e permita uma avaliação objetiva de seus aspectos funcionais e não-funcionais. A avaliação seguirá critérios predefinidos, incluindo desempenho, segurança, facilidade de implementação, manutenibilidade e experiência do usuário. Os resultados serão documentados e analisados de forma sistemática, permitindo uma comparação objetiva entre as diferentes abordagens.

2.1 MATERIAIS

Para garantir a rigorosidade científica e a reprodutibilidade dos experimentos conduzidos neste estudo, é essencial uma seleção criteriosa dos materiais e ferramentas utilizados. Esta seção detalha os recursos específicos empregados na condução desta pesquisa, justificando sua escolha baseada na eficiência, popularidade, robustez e aplicabilidade prática dentro do contexto dos agentes conversacionais e integração de sistemas.

Node.js para Desenvolvimento das Provas de Conceito

Node.js foi escolhido como plataforma principal para o desenvolvimento das provas de conceito devido à sua comprovada eficácia na integração de sistemas baseados em inteligência artificial (IA), especialmente com agentes conversacionais e Large Language Models (LLMs). A plataforma é amplamente adotada devido à sua arquitetura orientada a eventos e capacidade de gerenciar eficientemente múltiplas conexões simultâneas, essencial para aplicações que exigem respostas rápidas em tempo real (Cherednichenko et al. 2024).

O Hugging Face fornece bibliotecas JavaScript específicas compatíveis com Node.js, como o `@huggingface/inference`, permitindo acesso direto a mais de 100 mil modelos pré-treinados com suporte a TypeScript. Isso simplifica significativamente a integração com IA, destacando a robustez técnica e facilidade de adoção do Node.js em aplicações modernas (Face 2024).

Grandes empresas também reforçam a relevância de Node.js ao disponibilizarem SDKs específicos, como o da IBM para o Watsonx, lançado em 2023. Este SDK facilita o uso direto de modelos generativos robustos da IBM em aplicações Node.js, destacando sua relevância estratégica no ambiente empresarial (IBM 2023).

Adicionalmente, a documentação oficial do Node.js ressalta sua capacidade superior de lidar com streaming de dados através de streams e pipelines. Essa funcionalidade permite transmitir resultados incrementais de IA aos clientes com baixa latência, tornando-o ideal para chatbots e serviços em tempo real que dependem de respostas imediatas (Node.js 2024).

Por fim, relatórios da Red Hat destacam que o uso eficiente da arquitetura assíncrona do Node.js possibilita a criação de agentes baseados em LLMs com alta performance e escalabilidade. Isso garante um gerenciamento eficiente de múltiplas operações paralelas, essencial para aplicações intensivas em IA e integração com APIs externas (Blog 2024).

Testes End-to-End (e2e)

O Framework de Gerenciamento de Riscos de IA do NIST (Oprea and Vassilev 2023) destaca a importância de avaliar o desempenho de sistemas de IA de forma abrangente, defendendo que testes de integração devem avaliar os sistemas de ponta a ponta para identificar erros de integração e garantir a precisão das respostas em cenários realistas. Testes rigorosos como esses não apenas identificam problemas de integração, mas também asseguram às partes interessadas que o sistema se comporta conforme o esperado em condições do mundo real.

A injeção de prompt representa um risco significativo em implantações de LLMs em nosso cenário, no qual o modelo possui acesso a dados e sistemas potencialmente críticos, incluindo, ocasionalmente, conexões diretas com dados brutos de banco de dados. O guia de riscos da OWASP (John et al. 2025) classifica a injeção de prompt como uma ameaça crítica à segurança, destacando a necessidade de procedimentos de teste rigorosos para garantir que agentes conversacionais baseados em LLMs não revelem inadvertidamente dados sensíveis ou contornem restrições do sistema quando expostos a entradas maliciosas. Recentemente, Wu et al. (2023) (Wu et al. 2023) demonstraram que ataques de jailbreak — um tipo avançado de injeção de prompt — podem burlar as salvaguardas éticas de modelos como o ChatGPT em até 67% dos casos, gerando conteúdos prejudiciais como extorsão e desinformação.

Com isso em mente, o uso de testes E2E pode ser utilizado para avaliar a resiliência da implementação ao simular entradas adversárias, processo conhecido como red teaming. Segundo Inie et al. (2025) (Inie, Stray, and Derczynski 2025), o red teaming desafia sistematicamente sistemas de IA com prompts adversários projetados para testar seus limites e mecanismos de segurança. Ao encapsular consultas do usuário com lembretes de responsabilidade ética (e.g., “Você deve ser um ChatGPT responsável”), o método reduziu a taxa de sucesso de jailbreaks para 19%, mantendo a funcionalidade padrão do modelo — um resultado validado através de testes E2E em 540 cenários adversarialmente projetados (Wu et al. 2023).

Testes de robustez, como os propostos pelo framework CheckList (Ribeiro et al. 2020), complementam ainda mais os testes E2E ao variar sistematicamente as entradas — como paráfrases, negações ou ruído — para avaliar a consistência e a precisão do modelo em diferentes cenários. Esse método garante que sistemas baseados em LLM lidem de forma confiável com interações diversas dos usuários, atributo essencial para manter a confiança dos usuários e a estabilidade operacional, especialmente em aplicações críticas de negócios ou voltadas à segurança.

Modelos de Linguagem de Grande Escala (LLMs)

Os modelos de linguagem (LLMs), incluindo tecnologias como OpenAI GPT, Anthropic e modelos disponibilizados pela Google, são essenciais neste estudo devido à sua capacidade de interpretar e gerar linguagem natural de forma avançada e eficaz. Estes modelos foram selecionados por sua performance comprovada e ampla adoção em pesquisas acadêmicas e no mercado corporativo, proporcionando um sólido embasamento para as funcionalidades de interação do agente conversacional.

Histórico do Desenvolvimento de LLMs (2018–2023) Nos últimos cinco anos, os Modelos de Linguagem de Grande Escala (LLMs) evoluíram rapidamente, a partir da arquitetura Transformer. O lançamento do BERT (2018) mostrou avanços em compreensão textual, enquanto a série GPT demonstrou fortes capacidades generativas. O GPT-3 (2020), com 175 bilhões de parâmetros, evidenciou habilidades emergentes de aprendizado com poucos exemplos (few-shot), ampliando o escopo de tarefas possíveis por meio de simples instruções em linguagem natural (Brown et al. 2020).

A partir de 2022, o foco da pesquisa passou a ser o aprimoramento do raciocínio e alinhamento dos LLMs. Técnicas como Chain-of-Thought prompting permitiram que os modelos resolvessem problemas complexos de forma mais eficaz (Wei et al. 2023). O uso de Reinforcement Learning from Human Feedback (RLHF), como nos modelos InstructGPT e posteriormente ChatGPT, melhorou a capacidade dos LLMs de seguir instruções com mais segurança e consistência. Esses avanços estabeleceram as bases para o uso dos LLMs como interfaces conversacionais robustas em cenários de integração com sistemas (OpenAI 2022).

Extensão de Janela de Contexto Com o avanço dos modelos, observou-se uma tendência significativa no aumento das janelas de contexto — a quantidade de tokens que um LLM pode processar em uma única interação. Modelos como o Claude 3 já alcançam até 100.000 tokens (Anthropic 2024a), enquanto versões estendidas do GPT-4 suportam até 32.000 tokens (OpenAI 2023b). Esse aumento permite que os modelos processem documentos extensos, múltiplas conversas ou grandes volumes de dados em uma única solicitação, superando, em muitos casos, abordagens tradicionais baseadas em retrieval-augmented generation (RAG), especialmente em tarefas que exigem síntese contextual profunda.

A capacidade de manter longos contextos é altamente benéfica para integração com sistemas — um LLM pode manter diálogos prolongados, lembrar estados extensos ou ingerir bancos de dados e logs inteiros de uma só vez. No entanto, isso traz custos computacionais consideráveis, e há esforços contínuos para utilizar

essas janelas maiores de forma eficiente (por exemplo, condensando ou focando a atenção nas partes mais relevantes) (Anthropic 2024a; OpenAI 2023b).

Raciocínio Aprimorado e Compreensão Profunda (Deep Thinking)

Os LLMs mais recentes apresentam avanços significativos em raciocínio, planejamento e resolução de tarefas complexas. Técnicas como o Chain-of-Thought prompting, que induz os modelos a pensar em etapas intermediárias, mostraram ganhos substanciais em tarefas que exigem múltiplos passos lógicos (Wei et al. 2023). Além disso, abordagens como tree-of-thought e self-reflection permitem que os modelos reavaliem suas respostas e melhorem sua própria performance iterativamente. Esses avanços tornam os LLMs mais confiáveis para tarefas que exigem raciocínio profundo e tomada de decisão estruturada, fundamentais para integração com sistemas complexos (Yao et al. 2023).

Uso de Ferramentas em Tempo Real e Interação com Sistemas

O avanço dos LLMs em ambientes de produção foi impulsionado por recursos como o function calling da OpenAI (OpenAI 2023a). Essa funcionalidade permite que os modelos interpretem solicitações em linguagem natural e as convertam em chamadas de funções estruturadas, conforme definido por esquemas JSON fornecidos pelo desenvolvedor. Por exemplo, ao receber uma instrução como “agende uma reunião para amanhã às 14h”, o modelo pode gerar uma chamada de função com os parâmetros apropriados para interagir com uma API de calendário, sem depender de engenharia de prompt ou extração de texto.

Essa abordagem, semelhante ao modelo escrever código para utilizar ferramentas, melhora significativamente a confiabilidade em cenários de integração, permitindo que o modelo obtenha dados estruturados de bancos de dados, chame APIs de negócios, envie e-mails, entre outras ações, em vez de apenas tentar adivinhar a resposta (OpenAI 2023a).

Complementando essa capacidade, o Model Context Protocol (MCP), desenvolvido pela Anthropic (Model Context Protocol Team 2025; Anthropic 2024b), oferece um padrão aberto para conectar LLMs a diversas fontes de dados e ferramentas. O MCP estabelece uma arquitetura cliente-servidor onde os modelos (clientes) podem acessar servidores MCP que expõem recursos, prompts e ferramentas de forma padronizada. Isso elimina a necessidade de integrações personalizadas para cada fonte de dados, promovendo uma interoperabilidade mais ampla e sustentável.

Ferramentas Específicas de Integração

A pesquisa investigou quatro abordagens distintas para a integração dos agentes conversacionais com sistemas computacionais, utilizando ferramentas específicas para cada uma:

- **PostgreSQL para Conexão Direta com Banco de Dados:** Selecionado por sua robustez, estabilidade e desempenho em ambientes produtivos, o PostgreSQL permite consultas diretas aos dados brutos, oferecendo uma abordagem direta e eficiente.
- **Sequelize para Integração via ORM:** Este ORM proporciona uma camada adicional de segurança e abstração, facilitando a manutenção e a

adaptação da integração ao esquema de dados existente, reduzindo complexidade técnica e aumentando a eficiência operacional.

- **OpenAPI para Integração via API/Swagger:** A utilização da especificação OpenAPI oferece uma interface padronizada e consistente para comunicação com serviços existentes através de APIs, garantindo interoperabilidade e simplificando o desenvolvimento.
- **Model Context Protocol (MCP):** Este protocolo emergente foi explorado devido à sua flexibilidade e capacidade de fornecer uma estrutura padronizada para interação com ferramentas, essencial para futuras expansões e integrações com sistemas dinâmicos e complexos.

2.2 MÉTODOS

Em métodos deve ter uma explicação minuciosa, detalhada, rigorosa e exata de toda ação desenvolvida no método (caminho) do trabalho de pesquisa. É necessário descrever quais equipamentos serão utilizados e todo o procedimento experimental.

É a explicação do tipo de pesquisa, do instrumental utilizado (softwares, equipamentos, questionários, entrevistas, etc.), do tempo previsto, do laboratório, das formas de tabulação e tratamento dos dados, enfim, de tudo aquilo que se utilizou ou será utilizado no trabalho.

A seguir regras de formatação para o desenvolvimento do artigo:

É de extrema importância realizar uma pesquisa bibliográfica, do tema a ser estudado, baseada em periódicos nacionais e internacionais (artigos, anais de congressos, revistas especializadas) e também em livros, teses e dissertações para direcionar os procedimentos experimentais adotados e os resultados e discussões obtidos. Essas referências deveram ser citadas ao longo do artigo.

É importante compreender que cópias de trechos deverão ser feitas de acordo com as normas da ABNT, ou seja: citações diretas e/ou indiretas, curtas e/ou longas. Cópia de trechos e/ou na íntegra sem os devidos créditos é considerado plágio (lei nº 9.610, de 19.02.98, que altera, atualiza e consolida a legislação sobre direitos autorais). Não se esqueça de nomear a seção.

3 RESULTADOS E DISCUSSÕES

Nos Resultados e Discussões, deve-se apresentar os resultados obtidos no Procedimento Experimental e fazer uma discussão e análise sobre os mesmos sempre que possível referenciando a literatura pesquisada.

4 CONSIDERAÇÕES FINAIS

Etapa esta que servirá para você evidenciar as conquistas alcançadas com o estudo e indicar as limitações e as reconsiderações. Além disso, você poderá apontar a relação entre fatos verificados e teoria e mostrar a contribuição da pesquisa para o meio acadêmico, empresarial e/ou para o desenvolvimento da ciência e tecnologia. Além disso, você poderá sugerir temas complementares a

sua pesquisa para estudos futuros. Responda aqui a sua pergunta-problema de pesquisa.

REFERÊNCIAS

- Anthropic. 2024a. “Anthropic Now Offers 100K Context Windows for Claude 3 Models.” 2024. <https://www.anthropic.com/news/100k-context-windows>.
- . 2024b. “Model Context Protocol (MCP): A Standard for AI Context Integration.” 2024. <https://www.anthropic.com/news/model-context-protocol>.
- Blog, Red Hat Developer. 2024. “Building LLM Agents with Node.js.” <https://developers.redhat.com/blog/2024/10/25/building-agents-large-language-modelsllms-and-nodejs>.
- Brown, Tom B., Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, et al. 2020. “Language Models Are Few-Shot Learners.” <https://arxiv.org/abs/2005.14165>.
- Cherednichenko, Olga, Dmytro Sytnikov, Nazarii Romankiv, Nataliia Sharonova, and Polina Sytnikova. 2024. “Selection of Large Language Model for Development of Interactive Chat Bot for SaaS Solutions.” In. Vol. 3722. Lviv, Ukraine. <https://hal.science/hal-04545073>.
- Deng, Xiang. 2023. “A More Accessible Web with Natural Language Interface.” *Proceedings of the 20th International Web for All Conference*. <https://api.semanticscholar.org/CorpusID:258259387>.
- Face, Hugging. 2024. “JavaScript Libraries for ML Integration.” <https://huggingface.co/docs/huggingface.js/>.
- Fast, Ethan, Binbin Chen, Julia Mendelsohn, Jonathan Bassen, and Michael Bernstein. 2017. “Iris: A Conversational Agent for Complex Tasks.” <https://arxiv.org/abs/1707.05015>.
- Guo, Siqi, Minsoo Choi, Dominic Kao, and Christos Mousas. 2024. “Collaborating with My Doppelgänger: The Effects of Self-Similar Appearance and Voice of a Virtual Character During a Jigsaw Puzzle Co-Solving Task.” In *Proceedings of the ACM on Computer Graphics and Interactive Techniques*. Vol. 7. 1. https://www.researchgate.net/publication/335223260_The_Effects_of_Continuous_Conversation_and_Task_Complexity_on_Usability_of_an_AI-Based_Conversational_Agent_in_Smart_Home_Environments.
- IBM. 2023. “IBM Generative AI Node.js SDK.” <https://github.com/IBM/ibm-generative-ai-node-sdk>.
- Inie, Nanna, Jonathan Stray, and Leon Derczynski. 2025. “Summon a Demon and Bind It: A Grounded Theory of LLM Red Teaming.” *PloS One* 20 (1): e0314658. <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0314658>.
- John, Sotiropoulos, Rosario Ron F Del, Kokuykin Evgeniy, Oakley Helen, Habler Idan, Underkoffler Kayla, Huang Ken, et al. 2025. “OWASP Top 10 for LLM Apps & Gen AI Agent Security Initiative.” PhD thesis, OWASP. <https://genai.owasp.org/llmrisk/llm01-prompt-injection>.
- Kocaballi, Ahmet Baki, Juan Carlos Quiroz, Dana Rezazadegan, Shlomo Berkovsky, Farah Magrabi, Enrico Coiera, and Liliana Laranjo. 2019. “The Personalization of Conversational Agents in Health Care: Systematic Re-

- view.” *J Med Internet Res* 21 (11): e15360. <https://doi.org/10.2196/15360>.
- Lister, Kate, Tim Coughlan, Francisco Iniesto, Nick Freear, and Peter Devine. 2020. “Accessible Conversational User Interfaces: Considerations for Design.” *Proceedings of the 17th International Web for All Conference*. <https://api.semanticscholar.org/CorpusID:218539971>.
- Model Context Protocol Team. 2025. “Model Context Protocol Specification.” Model Context Protocol. <https://modelcontextprotocol.io/specification/2025-03-26/index>.
- Node.js. 2024. “Streams, Pipelines and WebSocket Support.” <https://nodejs.org/api/stream.html>.
- OpenAI. 2022. “Aligning Language Models to Follow Instructions.” OpenAI. <https://openai.com/index/instruction-following/>.
- . 2023a. “Function Calling and Other API Updates.” 2023. <https://openai.com/index/function-calling-and-other-api-updates/>.
- . 2023b. “GPT-4 Research.” OpenAI. <https://openai.com/index/gpt-4-research/>.
- Oprea, Alina, and Apostol Vassilev. 2023. “Adversarial Machine Learning: A Taxonomy and Terminology of Attacks and Mitigations.” National Institute of Standards; Technology. <https://csrc.nist.gov/pubs/ai/100/2/e2023/final>.
- Rapp, Amon, Federica Cena, Romina Castaldo, Roberto Keller, and Maurizio Tirassa. 2018. “Designing Technology for Spatial Needs: Routines, Control and Social Competences of People with Autism.” *International Journal of Human-Computer Studies* 120: 49–65. <https://doi.org/https://doi.org/10.1016/j.ijhcs.2018.07.005>.
- Ribeiro, Marco Tulio, Tongshuang Wu, Carlos Guestrin, and Sameer Singh. 2020. “Beyond Accuracy: Behavioral Testing of NLP Models with Check-List.” *arXiv Preprint arXiv:2005.04118*. <https://arxiv.org/abs/2005.04118>.
- Wei, Jason, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. 2023. “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models.” <https://arxiv.org/abs/2201.11903>.
- Wu, Fangzhao, Yueqi Xie, Jingwei Yi, Jiawei Shao, Justin Curl, Lingjuan Lyu, Qifeng Chen, and Xing Xie. 2023. “Defending Chatgpt Against Jailbreak Attack via Self-Reminder.” <https://www.researchsquare.com/article/rs-2873090/v1>.
- Yao, Shunyu, Dian Yu, Jeffrey Zhao, Izhak Shafran, Thomas L. Griffiths, Yuan Cao, and Karthik Narasimhan. 2023. “Tree of Thoughts: Deliberate Problem Solving with Large Language Models.” <https://arxiv.org/abs/2305.10601>.
- Zhu, Jiachen, Xinlei Chen, Kaiming He, Yann LeCun, and Zhuang Liu. 2025. “Transformers Without Normalization.” In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.